

Diskriminierungssensible Metadatenpraxis

Discrimination-Sensitive Metadata Practices

Moritz Mähr 

moritz.maehr@gmail.com

Universität Bern, Digital Humanities

Noëlle Schnegg 

noelle.schnegg@sciencespo.fr

Sciences Po

Fritekst ▼

Search...


From yyyy-mm-dd

✕

To yyyy-mm-dd

✕

Search 🔍

**Title** Knie Völkerschau**Resource type** Plakat**Date created** 1969?**Topic** PL000012.tif**Id** 1989-334/332**Accession number** Billedsamlingen. Plakatsamlingen. Cirkusplakater, 2°**Shelf mark** Litografi, flerfarvet tryk : mål: 500 x 350 mm**Comment** flerfarvet tegning af tre håndværkere ved arbejdet**Related** [Det Kgl. Biblioteks billedsamling](#)**Dimension** 1452 x 2084 (pixels)**Copyright** Materialet er beskyttet af ophavsret

This work is protected by copyright and may not be reproduced or copied without prior agreement with the copyright owners.

Is part of [Home/Billeder/Særudgivelser/Cirkus/Plakater](#)
[Home/Billeder/Samlinger/Plakatsamlingen/Cirkusplakater](#)

Daten sind nicht neutral

Data is not neutral

Normativität

Normativity

Grundlage

Daten und Metadaten erscheinen auf den ersten Blick als objektive Repräsentationen der Wirklichkeit, doch sind sie stets in historisch gewachsene Machtverhältnisse und normative Ordnungen eingebettet.

Jede Form von Daten- und Metadatenmodellierung – sei sie visuell, textuell oder strukturell – beruht auf normativen Entscheidungen, die oft unsichtbar bleiben.

«invisible hand of classification»

Bowker und Star 1999

«Technische Neutralität»

Entscheidungen in Interface, Datenmodell und Standardisierung erscheinen als rein technische Notwendigkeiten, obwohl sie normative Setzungen enthalten.

Item	Discussion
------	------------

Read [View history](#)

Eastern European peninsula, in the Black Sea and Sea of Azov, disputed between Ukraine (de jure) and Russia (de facto)

Kirim | Qırım | Kimmería | Tauriké | Crimean Peninsula | Crim. | Crimean P. | Taurike | Taurica | Kimmeria | Cimmeria

▼ In more languages

Configure

Language	Label	Description	Also known as
default for all languages	No label defined	—	
English	Crimea	Eastern European peninsula, in the Black Sea and Sea of Azov, disputed between Ukraine (de jure) and Russia (de facto)	Kirim Qırım Kimmería Tauriké Crimean Peninsula Crim. Crimean P. Taurike Taurica Kimmeria Cimmeria
American English	No label defined	No description defined	
German	Krim	Halbinsel im nördlichen Schwarzen Meer	Tauris
Alemannic	Krim	No description defined	

All entered languages

Appearance

hide

Text

☐ Small

☒ Standard

☐ Large

Width

☒ Standard

☐ Wide

Color (beta)

☐ Automatic

☒ Light

☐ Dark

[wikidata.org/wiki/Q7835](https://www.wikidata.org/wiki/Q7835)

country	Ukraine	
	start time	12 February 1991
	nature of statement	de jure
	▼ 0 references	
	Russia	
	start time	2014
	object of statement has role	de facto
	▼ 0 references	
	Soviet Union	
	start time	29 December 1922 <i>Gregorian</i>
	end time	12 February 1991
	▼ 0 references	
	Russian Empire	
	end time	1918
	start time	1783
	▼ 0 references	
	Crimean Khanate	
	start time	1441
	end time	1783

Appearance hide

Text

- ☐ Small
- ☒ Standard
- ☐ Large

Width

- ☒ Standard
- ☐ Wide

Color (beta)

- ☐ Automatic
- ☒ Light
- ☐ Dark

File Discussion

Read Edit View history

7 / 53

Das Beispiel Krim

Was das Beispiel zeigt

- Wikidata führt die Krim sowohl als Teil der Ukraine ("de jure") als auch Russlands ("de facto").
- Viele verknüpfte Objekte wie Städte oder administrative Einheiten übernehmen diese Mehrdeutigkeit nicht konsistent oder bilden einzig die ukrainische Perspektive ab.
- Die Karte operiert mit einem klaren Framing zugunsten der ukrainischen Souveränität und blendet alternative Klassifikationsoptionen, wie etwa die Bezeichnung "Republik Krim" als Teil Russlands, weitgehend aus.

In der Umsetzung

- 1 Transparente Dokumentation von Modellierungsentscheidungen (Schema, Version, Geltungsbereich)
- 2 Parallele Felder für Mehrperspektivität (*de jure/de facto*, Selbst- und Fremdbezeichnungen)
- 3 Überprüfbare Quellen- und Provenienzangaben
- 4 Explizite, maschinenlesbare Markierung von Konflikten und Unsicherheiten (Status, Zeitraum, räumliche Gültigkeit)

Direkte Diskriminierung

Direct Discrimination

Direkte Diskriminierung

Direct Discrimination

Diskriminierung · 1 / 6

Eine Regel, Entscheidung oder Handlung ist **direkt diskriminierend**, wenn sie Personen aufgrund eines geschützten Merkmals ungleich behandelt und diese Ungleichbehandlung nicht durch einen legitimen, verhältnismässigen Zweck gedeckt ist.

Kernelemente



- 1 Unmittelbare Ungleichbehandlung:** Eine Regel oder Praxis behandelt Personen explizit unterschiedlich.
- 2 Merkmalsbezug:** Die Ungleichbehandlung knüpft an ein tatsächliches oder zugeschriebenes (geschütztes) Merkmal an.
- 3 Fehlende Rechtfertigung:** Es gibt keinen legitimen, verhältnismässigen Zweck, der die Ungleichbehandlung trägt.



Pages



Export



 BILD

"Austral***** Bonny"



 VÖLKERSCHAUEN



 FOTOKARTEN ZUR ANSICHT

 ARCHIVE MAP

 ORDER

Identification

Title	"Austral***** Bonny"
Reference Code / Identification number	BSL 1001 N 2.13
Stage	Dossier
Period of origin	1883
Type of item	Bild
Author	Taeschler-Signer, Basel;
Anzahl	6

Content and internal order

Related records

Share

Indirekte Diskriminierung

Indirect Discrimination

Indirekte Diskriminierung

Indirect Discrimination

Diskriminierung · 2 / 6

Indirekte Diskriminierung liegt vor, wenn formal neutrale Kriterien, Methoden oder Regelungen zur Erhebung, Auswahl, Beschreibung oder Interpretation historischer Daten in ihrer Wirkung systematisch bestimmte Gruppen benachteiligen.

Das betrifft zum Beispiel unterdokumentierte Gruppen oder Praktiken, die durch etablierte Routineprozesse weiter marginalisiert werden.

Kernelemente

- 1 Formale Neutralität:** Kriterien oder Prozesse wirken auf den ersten Blick allgemeingültig.
- 2 Ungleichwirkung:** In der Anwendung entstehen systematische Nachteile für bestimmte Gruppen (Disparate Impact).
- 3 Alternative Gestaltung:** Es gäbe weniger benachteiligende, fachlich gleichwertige Verfahren oder Ausnahmen.

Élites suisses

Base de données des élites suisses

© Mark Henley

[Accueil](#) [Description](#) [Visualisations](#) [Politique de gestion des données](#) [Contact](#)

[OBELIS](#) [Blog](#) [Liens](#)

Index des personnes

50'755 personnes avec au moins 1 mandat répertoriées

[A](#) [B](#) [C](#) [D](#) [E](#) [F](#) [G](#) [H](#) [I](#) [J](#) [K](#) [L](#) [M](#) [N](#) [O](#) [P](#) [Q](#) [R](#) [S](#) [T](#) [U](#) [V](#) [W](#) [X](#) [Y](#) [Z](#)

[Aa - Ak](#) [Al - Az](#)

Aa - Ak

Nom	Prénom	Dates	Mandats	Projet
Aa, von der	Albert	1894-1978	5	
Aamot	M. Kjell	1950-	1	 
Ab Yberg-Wyss	Alois	1878-1959	7	
Abächerli	Alois	1895-1976	1	
Abächerli	Claudio		1	
Abächerli-Halter	Otto	1925-	1	
Abanin	Dmitry		1	
Abate	Fabio	1966-	14	 
Abbasoglu-Akturan	Devrim	1977-	1	



[Index des Personnes](#)

[Index des Entités](#)

elitessuisses.unil.ch

Strukturelle Diskriminierung

Structural Discrimination

Strukturelle Diskriminierung

Structural Discrimination

Diskriminierung · 3 / 6

Strukturelle Diskriminierung bezeichnet Benachteiligungen, die in etablierten Praktiken der Sammlung, Dokumentation, Bewahrung und Zugänglichmachung verankert sind.

Ordnungen des Archivierens, Katalogisierens und Kuratierens reproduzieren häufig patriarchale, koloniale und heteronormative Sichtweisen.

Kernelemente

- 1 Einbettung in Routinen und Infrastrukturen:** Benachteiligungen entstehen nicht primär durch einzelne Akte, sondern durch gewachsene Standards, Prozesse und Klassifikationen.
- 2 Kumulativität und Pfadabhängigkeit:** Viele kleine Entscheidungen verstärken sich über Zeit und werden schwer revidierbar.
- 3 Unsichtbarkeit als Normalform:** Ungleichheiten erscheinen als "Datenlage" oder "Sachzwang" und werden dadurch stabilisiert.



Unterfelder / Datenelemente

Code

Bemerkungen

Anwendungskontext

Institution, die die Aussage des Feldinhaltes verantwortet

Validierung

Befugnisse

Beispiele

Geschlecht

STA-Notation:
GND-DF-PERSON-
GESCHLECHT

Das Datenfeld enthält die Geschlechtsangabe von Personen in normierter Form.

Wiederholung Ja

Format

032T

PICA+

375

- PICA3
- Alma
- Aleph

Unterfelder / Datenelemente	PICA3	PICA+	Alma	Aleph	Bezeichnung	Wdhlg.
	;	\$a	\$a	\$a	Code	Ja
	\$v	\$v	\$9v:	\$v	Bemerkungen	Ja
	\$C	\$C	\$9C	\$C	Anwendungskontext	Ja
	\$5	\$5	\$5	\$5	Institution, die die Aussage des Feldinhaltes verantwortet	Nein

Unterfelder / Datenelemente

Code



Unterfelder / Datenelemente

Code

Bemerkungen

Anwendungskontext

Institution, die die Aussage
des Feldinhaltes
verantwortet

Validierung

Befugnisse

Beispiele

PICA3

PICA+

Alma

Aleph

Bezeichnung

Wdhlg.

Unterfelder / Datenelemente

Code



- [männlich](#)
- [weiblich](#)

Erfassen Sie jeweils einen der folgenden Codes:

	PICA	Alma, Aleph (ISO 5218)
männlich	m	1
weiblich	f	2



In der Regel wird nur eine Geschlechtsangabe erfasst. Eine von der codierten Form abweichende Geschlechtsangabe wie beispielsweise intersexuell darf im Datenfeld [Historische oder biographische Angaben](#) als Freitext erfasst werden, wenn diese Angabe sich im Werk der Person widerspiegelt bzw. Teil der öffentlichen Darstellung ist.



Stand: Juni 2026

sta.dnb.de/doc/GND-DF-PERSON-GESCHLECHT

Institutionelle Diskriminierung

Institutional Discrimination

Institutionelle Diskriminierung

Institutional Discrimination

Diskriminierung · 4 / 6

Institutionelle Diskriminierung entsteht, wenn interne Ordnungen und Routinen von einer spezifischen Gedächtnisinstitution systematisch bestimmte Gruppen benachteiligen.

Sie verschränkt sich oft mit struktureller Diskriminierung.

Kernelemente

- 1 Organisationsspezifische Regeln:** Benachteiligung wird durch interne Policies, Zuständigkeiten, Budgets oder Systemsentscheidungen erzeugt.
- 2 Reproduzierbarkeit im Betrieb:** Effekte sind wiederkehrend (nicht zufällig), weil sie in Prozessen, Rollen und Steuerung verankert sind.
- 3 Verantwortung und Governance:** Gegenmassnahmen erfordern klare Zuständigkeiten, Dokumentation und überprüfbare Entscheidungswege.

[Werke](#)[Bilder](#)[zur Trefferliste](#)

1 von 1 Treffern



C 9



Ejmiacin * [(Kathedrale) Ejmiacin] Platz an der Nordseite * Genozid-Denkmal * Ejmiacin?, 1965 * Neg.-Nr. B 22.566/20 * Aufnahme 1995

Genozid-Denkmal

Standort:	Ejmiacin, Kathedrale Ejmiacin, Platz an der Nordseite
Datierung:	1965
Sachbegriff:	Denkmal
Gattung:	Skulptur
Ortsbezug:	Entstehungsort: Ejmiacin?
Objekt-PID:	http://id.bildindex.de/thing/0001543069

Link zu dieser Seite:	https://www.bildindex.de/document/obj20544407
Datensatz von:	Bildarchiv Foto Marburg
Letzte Aktualisierung 	19.02.2026

Siehe auch

[Mehr Werke aus der Zeit von 1965](#)[Mehr Werke in Ejmiacin](#)[bildindex.de/document/obj20544407](https://www.bildindex.de/document/obj20544407)

Statistische Diskriminierung

Statistical Discrimination

Statistische Diskriminierung

Statistical Discrimination

Diskriminierung · 5 / 6

Statistische Diskriminierung bezeichnet die Benachteiligung von Individuen, wenn unter unvollständiger Information Entscheidungen auf gruppenbezogenen Durchschnittswerten beruhen.

Kernelemente

- 1 Informationsasymmetrie:** Über Einzelne liegen weniger, über Gruppen mehr Information vor. Entscheidungen werden auf Gruppenstatistiken gestützt.
- 2 Gruppenzuschreibung:** Wahrscheinlichkeiten oder Durchschnitte werden auf einzelne Personen übertragen.
- 3 Effekt:** Benachteiligung von Personen, die nicht dem Gruppenprofil entsprechen.

**Intersektionale
Diskriminierung**

Intersectional Discrimination

Intersektionalität


Intersectionality

Diskriminierung · 6 / 6

Intersektionalität bezeichnet einen Analyseansatz, der Diskriminierung nicht als isolierte Einzelphänomene (zum Beispiel nur Sexismus oder nur Rassismus) versteht, sondern als verflochtene, sich wechselseitig konstituierende Macht- und Ungleichheitsverhältnisse.

Nicht additiv

Es geht nicht darum, Diskriminierungen additiv zu summieren. Kategorienwahl, Modellierung und Beschreibung sind oft so angelegt, dass bestimmte Gruppen **weder in der Kategorie A noch in der Kategorie B** sichtbar werden, sondern zwischen beiden verschwinden (Crenshaw 1989; Collins 2000).



Weder in A noch in B sichtbar:
verschwinden zwischen den Kategorien

nach Crenshaw 1989

Intersektionalität in der Metadatenpraxis

Wo intersektionale Effekte entstehen

- **Klassifikationslogik:** Facetten oder Normdaten sind so strukturiert, dass „Frauen“ implizit als „weiss“ und „Schwarze Menschen“ implizit als „männlich“ gelesen werden.
- **Retrieval-Logik:** Such- und Filterfunktionen behandeln Kategorien als unabhängig. Eine Suche nach „Frauen“ liefert dann vor allem Datensätze, die in dominanten Kontexten bereits gut beschrieben wurden.
- **Quellenlage und Erschliessung:** Historische Überlieferung und institutionelle Sammelpraktiken sind ungleich verteilt.

Praktische Implikationen

- 1 **Mehrfachkategorisierung ermöglichen:** Kombinationen von Kategorien nicht technisch ausschliessen.
- 2 **Schnittmengen prüfen:** Qualitätskontrollen auch für Kreuzungen, zum Beispiel „Frauen + Minderheitensprache“.
- 3 **Granularität vs. Schutz:** Je granularer Merkmale kombiniert werden, desto leichter kann Re-Identifikation werden.

Bias

Verzerrungen und Fehler in Daten, Algorithmen und Nutzung

Was ist Bias?

Unter einem **Bias** wird eine Verzerrung – eine systematische Abweichung einer objektiven Darstellung – verstanden.

Technisch entsteht ein Bias in Forschungsdaten etwa durch

- eine unausgewogene Datenauswahl,
- eine stereotypisierende Begriffsauswahl,
- algorithmische Vorannahmen.

Jede historische Darstellung ist selektiv und perspektivisch.

Unterschied zu Diskriminierung

Bias

beschreibt in erster Linie eine diagnostizierbare Verzerrung in einem technischen oder methodischen Prozess.

Diskriminierung

bezeichnet die sozial wirksame Benachteiligung von Personen und Gruppen in ungleichen Machtverhältnissen.

Ein System kann damit statistisch "fairer" werden und dennoch diskriminierend wirken, wenn es historisch belastete Kategorien fortschreibt, Ausschlüsse reproduziert oder nur dominante Nutzergruppen als implizite Norm behandelt (Buolamwini und Gebru 2018; Noble 2018).

Drei Familien von Bias

Daten

Data Bias

- 1 Messfehler
- 2 Auslassungsfehler
- 3 Repräsentationsfehler
- 4 Aggregationsfehler
- 5 Stichprobenfehler
- 6 Längsschnittfehler
- 7 Historische Verzerrung
- 8 Populationsfehler

Algorithmen

Bias in Algorithms

- 9 Algorithmischer Fehler
- 10 Evaluationsfehler

Nutzerinteraktion

User Interaction Bias

- 11 Darstellungsfehler
- 12 Rangfolgenfehler
- 13 Popularitätsfehler
- 14 Emergenter Fehler
- 15 Selbstselektionsverzerrung
- 16 Soziale Verzerrung
- 17 Verhaltensverzerrung
- 18 Zeitliche Verzerrung
- 19 Inhaltsproduktionsfehler

Die Taxonomie ordnet Verzerrungen nach dem Ort, an dem sie entstehen. Die Formen können unabhängig voneinander auftreten.

Taxonomie nach Mehrabi u. a. (2021)

Verzerrung in Daten

Data Bias

8 Formen

Messfehler

Measurement Bias

Daten · 1 / 8

Bias, der durch fehlerhafte, unvollständige oder inadäquate Messung von Variablen entsteht.

Beispiel 1

In digitalen Editionen historischer Texte wird "Bedeutung" oft über die Häufigkeit bestimmter Begriffe erfasst, doch fehlerhafte OCR-Erkennung – etwa wenn das historische "f" nicht als "s" erkannt wird – oder uneinheitliches Tagging führen leicht zu systematischen Verzerrungen.


Beispiel 2

Erfassung von Geschlecht in historischen Volkszählungen: "Beruf: Haushaltsvorstand" wird in digitalen Datenbanken oft als "männlich" codiert, was weibliche Haushaltsvorstände systematisch ausschliesst.

Beispiel 1 · OCR



Beispiel 2 · Volkszählung



Auslassungsfehler

Omitted Variable Bias


Daten · 2 / 8

Entsteht, wenn relevante Variablen im Modell fehlen, was zu verzerrten Ergebnissen führt.


Beispiel

Eine digitale Netzwerkanalyse historischer Korrespondenz lässt informelle Kommunikationswege (zum Beispiel persönliche Treffen, mündliche Überlieferung) aus, was zu verzerrten Interpretationen von Kommunikationsnetzwerken führt.

Realität



Datensatz



— erfasst

- - - nicht erfasst: Treffen, Gespräche

Repräsentationsfehler

Representation Bias


Daten · 3 / 8

Bias durch nicht-repräsentative Stichproben, zum Beispiel geografische oder demografische Unterrepräsentation im Datensatz.

Beispiel

Digitalisierte Zeitungsarchive decken meist nur bestimmte (oft bürgerliche oder urbane) Presse ab; Arbeiterzeitungen, marginalisierte Gruppen oder nicht-deutschsprachige Publikationen fehlen und werden in der Forschung unsichtbar.

Erschienene Presse




- bürgerliche, urbane Presse
- Arbeiterzeitungen
- marginalisierte Gruppen, nicht-deutschsprachig

Digitalisierung



Digitalisiertes Archiv



□ fehlt im Archiv

Aggregationsfehler

Aggregation Bias

Daten · 4 / 8

Fehlerhafte Verallgemeinerung von Gruppenergebnissen auf Individuen oder Subgruppen.

Simpson's Paradox


Aggregierte Trends können täuschen, weil sich Zusammenhänge auf Subgruppenebene ins Gegenteil verkehren. *Beispiel:* Eine Methode scheint insgesamt erfolgreicher, ist aber in allen Teilgruppen weniger erfolgreich, die Aggregation verschleiert dies.

Modifiable Areal Unit Problem (MAUP)

Ergebnisse hängen von der gewählten räumlichen Aggregation ab. *Beispiel:* Zusammenfassung von unterschiedlichen Sozialstrukturen (zum Beispiel alle "Arbeiter" im 19. Jh.) überdeckt regionale Unterschiede – etwa zwischen Textilarbeiterinnen im Ruhrgebiet und Landarbeitern in Ostpreussen.


Simpson-Paradox · Erfolgsquote in %

■ Methode X ■ Methode Y



Daten: Nierenstein-Studie (Charig u. a. 1986)

MAUP · Zusammenfassen über Regionen



Stichprobenfehler

Sampling Bias


Daten · 5 / 8

Bias durch nicht-zufällige Auswahl von Stichproben führt zu mangelnder Generalisierbarkeit.

Beispiel


Oral History-Projekte, die ausschliesslich mit Zeitzeugen arbeiten, die aktiv Kontakt zu Forscher*innen aufnehmen, erfassen tendenziell eher politisch engagierte oder bildungsnahe Akteur*innen.

Zeitzeug*innen



meldet sich selbst

Interviews



Stichprobe: **5 von 6**
Population: **6 von 24**

 politisch engagiert, bildungsnahe
 andere

Längsschnittfehler

Longitudinal Data Fallacy


Daten · 6 / 8

Fehlschluss durch Vermischung von Kohorten in Querschnittsdaten, anstatt echte zeitliche Entwicklung zu betrachten.

Beispiel

Analyse von Wikidata-Einträgen zu historischen Persönlichkeiten über Jahrzehnte hinweg, ohne zu berücksichtigen, dass sich die Erfassungsregeln oder Community-Praktiken im Zeitverlauf ändern.

Einträge zu historischen Personen (schematisch)



Sprung = neue Regel, nicht neue Geschichte

Direkter Vergleich: «Die Welt hat sich verändert» – oder die Erfassung?

Historische Verzerrung

Historical Bias

Daten · 7 / 8


Bias, der bereits in der gesellschaftlichen Realität existiert und sich in den Daten widerspiegelt, auch bei perfekter Stichprobe.

Beispiel

Digitale Repositorien, die historische Demografie abbilden, spiegeln patriarchale Strukturen wider: Die geringe Zahl von "Frauen in Führungspositionen" ist kein Datenfehler, sondern gesellschaftliche Realität.

Historische Gesellschaft

Führungspositionen




 Männer

 Frauen

Datensatz

Führungspositionen



Quellen

→
perfekte
Stichprobe

Daten korrekt – Ungleichheit liegt in der Geschichte, nicht im Datenfehler

Populationsfehler

Population Bias


Daten · 8 / 8

Unterschiede zwischen Nutzenden der Plattform und der Zielpopulation, zum Beispiel durch Demografie.

Beispiel

Wikidata-Einträge zu Historiker*innen stammen überproportional von männlichen, westlichen Beitragenden, was sich in der Sichtbarkeit und Kategorisierung niederschlägt.


Beitragende



erfassen



Zielpopulation



Historiker*innen weltweit

 männlich, westlich

 andere Gruppen

Sichtbarkeit folgt den Beitragenden, nicht der Zielpopulation

Verzerrung durch Algorithmen

Bias in Algorithms

2 Formen

Algorithmischer Fehler

Algorithmic Bias

Algorithmen · 1 / 2

Bias, der durch algorithmische Designentscheidungen entsteht, unabhängig von Bias in den Daten (zum Beispiel durch Auswahl der Optimierungsfunktion).

Beispiel

Topic Modeling von philosophischen Texten ergibt "Themen", die Resultat von Wortlisten und Stoppwortdefinitionen sind, aber von Nicht-Expert*innen als inhaltlich signifikante Topoi interpretiert werden.

Gleiche Texte



Stoppwortliste A
+ Topic Model

«Themen»

Gott

Seele

Geist

Stoppwortliste B
+ Topic Model

Natur

Vernunft

Erkenntnis

Andere Designentscheidung → andere «Themen»

Nicht-Expert*innen lesen sie als inhaltliche Topoi.

Evaluationsfehler


Evaluation Bias

Algorithmen · 2 / 2

Verzerrung durch ungeeignete oder unausgewogene Benchmarks bei der Modellbewertung.

Beispiel

Trainings- und Testsets für Named-Entity-Recognition-Modelle im Bereich Geschichte verwenden hauptsächlich Quellen des 20. Jahrhunderts. Modelle performen deshalb schlecht bei mittelalterlichen oder frühneuzeitlichen Texten.



Benchmark prüft vor allem das 20. Jahrhundert

Illustrative Werte

Verzerrung durch Nutzerinteraktion

User Interaction Bias

9 Formen

Darstellungsfehler

Presentation Bias

Nutzung · 1 / 9

Ungleichgewicht, das durch visuelle, typografische oder layoutbezogene Hervorhebungen entsteht. Interface-Entscheidungen lenken Aufmerksamkeit und Interpretationsrahmen, bevor inhaltliche Qualität bewertet wird.

Beispiel

Quellen, die ohne Einschränkungen zugänglich sind, werden farblich hervorgehoben im Archivkatalog. Damit werden sie häufiger angeklickt und verdrängen die weniger zugänglichen Quellen überdurchschnittlich.

Archivkatalog: Suchergebnisse



Ratsprotokolle 1850–1900

frei zugänglich



Nachlass F. Muster



eingeschränkt



Fotosammlung Hafen

frei zugänglich



Vormundschaftsakten




eingeschränkt



Zeitungsausschnitte

frei zugänglich

Klicks



Hervorhebung lenkt Klicks – vor jeder Prüfung des Inhalts

Rangfolgenfehler

Ranking Bias

Nutzung · 2 / 9

Systematische Verzerrung durch Sortierlogiken, die Klicks, Zitationszahlen oder Metadatenfülle belohnen. Höhere Position führt zu mehr Aufmerksamkeit, was die ursprüngliche Rangordnung verstärkt, unabhängig von Relevanz.


Beispiel

Museumsportal sortiert nach "Meist betrachtet". Kolonialzeitliche Exponate mit früher Social-Media-Reichweite dominieren, während neu katalogisierte Objekte aus dem Globalen Süden kaum Sichtbarkeit erhalten.

Sortierung: Meist betrachtet ▼

- 1  Kolonialzeitliches Exponat
- 2  Kolonialzeitliches Exponat
- 3  Kolonialzeitliches Exponat
- 4  Kolonialzeitliches Exponat
- 5  Neu katalogisiert, Globaler Süden
- 6  Neu katalogisiert, Globaler Süden

Aufmerksamkeit



Position erzeugt Aufmerksamkeit, nicht Relevanz

Popularitätsfehler

Popularity Bias


Nutzung · 3 / 9

Beliebtere Objekte werden häufiger gezeigt und verstärken dadurch ihre Popularität, unabhängig von Qualität.

Beispiel

In Crowdsourcing-Projekten zu alten Handschriften dominieren wenige besonders aktive User, sodass ihre Lesarten überproportional häufig übernommen werden.

Übernommene Lesarten pro User



User, nach Aktivität sortiert



Wenige aktive User prägen, was als Lesart gilt

Emergender Fehler


Emergent Bias

Nutzung · 4 / 9

Bias, der erst durch langfristige Interaktion mit Nutzenden oder gesellschaftlichen Wandel entsteht.

Beispiel

Ein digitales Editionsprojekt zu mittelalterlichen Urkunden wird ursprünglich als Forschungsinfrastruktur für Editionsphilologie konzipiert. Mit der Zeit beginnen jedoch genealogische Communities, die Daten für Familienforschung zu nutzen. Dadurch verschiebt sich die Nachfrage in Richtung Namens- und Ortsindexierung. Die Infrastrukturbetreiber passen ihre Metadatenstrukturen und Suchfunktionen an diese Nutzergruppen an, was wiederum philologische Tiefeninformationen (zum Beispiel Variantenkritik) systematisch marginalisiert.



Variantenkritik wird erst mit der Zeit an den Rand gedrängt

Selbstselektionsverzerrung

Self-Selection Bias

Bias durch selbstselektierende Teilnehmende, zum Beispiel in Umfragen.

Beispiel


Digitalisierungsprojekte zu Privatarchiven werden eher von Familien mit hohem kulturellem Kapital initiiert, während marginalisierte Familien seltener teilnehmen.

Familien



Aufruf:
Privatarchive
digitalisieren

Digitalisiert



■ hohes kulturelles Kapital ■ marginalisierte Familien

Wer sich meldet, **prägt das Archiv**

Soziale Verzerrung


Social Bias

Nutzung · 6 / 9

Individuelle Entscheidungen werden durch soziale Einflüsse verzerrt.

Beispiel

Bei kollaborativen Transkriptionsprojekten orientieren sich neue User*innen an den Lesegewohnheiten erfahrener Transkribierender und übernehmen deren Fehler.



Ein Lesefehler wird zur Norm im Projekt

Verhaltensverzerrung

Behavioral Bias

Nutzung · 7 / 9

Unterschiedliches Verhalten von Nutzenden je nach Plattform, Kontext oder Zeit.

Beispiel

Historiker*innen recherchieren systematischer, während Lai*innen häufig nach Familiennamen oder spektakulären Ereignissen suchen. Dies beeinflusst Zugriffszahlen.

Historiker*innen



Bestand → Serie → Dossier

Signatur PA 123

Lai*innen



«Müller»

«Stadtbrand 1917»

«Familie Meier»

Zugriffszahlen

Familiennamen



Ereignisse



Verwaltungsserien



Zugriffe zeigen Suchverhalten, nicht Bedeutung

Zeitliche Verzerrung

Temporal Bias


Nutzung · 8 / 9

Verzerrungen, die sich aus zeitlichen Veränderungen in Verhalten oder Population ergeben.

Beispiel

Die Häufigkeit von Suchbegriffen in Archiven schwankt mit Debatten (zum Beispiel "Pandemie" 2020/21), was langfristige Analysen verzerrt.

Suchanfragen «Pandemie» im Archivkatalog



Index, Höchstwert = 100 · illustrative Werte

Spitzen spiegeln Debatten, nicht Bestände

Inhaltsproduktionsfehler

Content Production Bias


Nutzung · 9 / 9

Verzerrungen, die auf Unterschieden in Struktur, Lexik, Semantik und Syntax nutzergenerierter Inhalte beruhen.

Beispiel

Digitale Foren zur Wissenschaftsgeschichte werden auf Englisch dominiert; andere Sprachen sind unterrepräsentiert.

Beiträge in einem Forum zur Wissenschaftsgeschichte



Illustrative Werte

Eine Sprache bestimmt Begriffe, Struktur und Sichtbarkeit

Quellen

Moritz Mähr: *Diskriminierungssensible Metadatenpraxis*. Kapitel «Theorie: Schlüsselbegriffe und Konzepte», Abschnitte «Diskriminierung in und durch Daten» und «Verzerrungen und Fehler (Bias)».

<https://moritz-maehr.quarto.pub/diskriminierungssensible-metadatenpraxis/#sec-theorie>

Taxonomie: Mehrabi, Ninareh, Fred Morstatter, Nripsuta Saxena, Kristina Lerman und Aram Galstyan. 2021. «A Survey on Bias and Fairness in Machine Learning». *ACM Computing Surveys* 54 (6): 1–35. <https://doi.org/10.1145/3457607>

Zahlen zum Simpson-Paradox: Charig, C. R., D. R. Webb, S. R. Payne und J. E. Wickham. 1986. «Comparison of Treatment of Renal Calculi by Open Surgery, Percutaneous Nephrolithotomy, and Extracorporeal Shockwave Lithotripsy». *BMJ* 292 (6524): 879–82.

<https://doi.org/10.1136/bmj.292.6524.879>

Weitere zitierte Literatur (Bowker und Star 1999; Crenshaw 1989; Collins 2000; Buolamwini und Gebru 2018; Noble 2018) im Literaturverzeichnis des Handbuchs.